

Deep Learning: Advanced Models and Methods · DL26

Feature-Based Knowledge Distillation

GRUPPO
G26

ID PROGETTO
4

AUTORE
Salvatore Iurato



REPOSITORY GITHUB

Drake9098 / Feature-based-knowledge-distillation

L'equilibrio tra accuratezza e latenza

OBIETTIVO

I modelli deep sono accurati ma costosi in deployment. La **Knowledge Distillation** trasferisce conoscenza da un teacher grande a uno student compatto. Il progetto esplora la **distillazione feature-based**: lo student impara dai logit del teacher e dalle sue rappresentazioni interne, non solo dalle predizioni finali.

QUESITO INIZIALE

Una ResNet-18 compatta può eguagliare o superare l'accuratezza di una baseline CE-only distillando da una ResNet-50 fine-tuned su CIFAR-100? Quale strategia funziona meglio?

Ipotesi

1

Vanilla KD > CE

Uno student con vanilla KD sui logit (Hinton et al.) dovrebbe superare il training from scratch con sola cross-entropy.

2

Feature-based

FitNets (Romero et al.) e Attention Transfer (Zagoruyko & Komodakis) dovrebbero migliorare lo student allineando le rappresentazioni intermedie, a costo di pipeline più complesse.

3

Hint layer e T

La scelta degli hint layer in FitNets e la temperatura di distillazione T influenzano la convergenza.

CIFAR-100 e pipeline di distillazione

Dataset CIFAR-100

50k

Training set

10k

Test set

100

Classi fine-grained · 500 img/classe

32×32

Immagini RGB

Data augmentation

- **RandomCrop** 32 con padding 4
- **RandomHorizontalFlip**
- **RandomRotation** 15°
- **ColorJitter** brightness / contrast / saturation 0,2
- **Normalizzazione ImageNet** (μ , σ)
- **Test set:** no augmentation

Pipeline sperimentale

T**Teacher fine-tuned**

ResNet-50 · checkpoint condiviso per ogni student

**B****Baseline student**

ResNet-18 · training CE from scratch

**V****Vanilla KD**

distillazione sui logit

F**FitNets**

allineamento hint layer

A**Attention Transfer**

mappe di attenzione

Architetture CIFAR-adapted e tre strategie di distillazione

Teacher ResNet-50

- **Stem CIFAR-adapted:** conv1 3×3 s1, maxpool1 disabilitato, fc a 100 classi
- **Pretrained ImageNet-1K:** fine-tuning per compatibilità
- **Checkpoint unico** fine-tuned una volta, poi congelato e riusato in ogni run di distillazione

Student ResNet-18

- **Stesso stem CIFAR** del teacher e fc a 100 classi
- **Architettura condivisa** tra baseline CE-only e tutti gli student distillati
- **Teacher frozen:** in distillazione si aggiornano solo i parametri student (e i regressori FitNet in Stage 1)

Vanilla KD

- **Soft target** dal teacher a temperatura T , combinato con le label hard via CE
- **Logit morbidi** con fattore T^2 per mantenere efficaci i gradienti del termine KL
- **Single-stage:** nessun hint layer, solo i logit del teacher

$$L_{\text{KD}} = \alpha \cdot \text{CE} + (1 - \alpha) \cdot T^2 \cdot \text{KL}$$

FitNets

- **Stage 1:** allineamento hint con MSE e regressore conv 1×1 tra feature student e teacher
- **Stage 2:** KD sull'intera rete con warm-start dai pesi di Stage 1
- **Hint Middle, Deep, Full:** supervisione su layer2, layer4 o su tutti e quattro gli stage

$$L_{\text{hint}} = \text{MSE}(R(h_s), h_t)$$

Attention Transfer

- **Single-stage:** KD sui logit più allineamento spaziale delle mappe di attenzione
- **Mappe F²-sum** estratte da layer1–layer4, normalizzate e confrontate in L2
- Obiettivo: replicare *dove* guarda il teacher, non solo *cosa* predice

$$L = L_{\text{KD}} + L_{\text{AT}}$$

FitNet Deep (T=20) a 81,11% colma circa il 58% del gap teacher-student

Metodo	T	Top-1	MB
Teacher	—	82,16	90,63
Baseline CE	—	76,75	42,84
Vanilla KD	20	80,92	42,84
FitNet Deep ★	20	81,11	42,84
FitNet Full	8	80,76	42,84
AT + KD	20	79,62	42,84



La KD migliora l'accuratezza di +2,7–4,4 pp rispetto alla baseline

Il capacity gap: perché Full e AT sottoperformano

Over-regularization (Full & AT)

- Allineamento su **tutti e 4 i layer**: lo student imita la struttura interna del teacher invece di confini discriminativi per 100 classi
- Vincoli feature-level **competono** con la classificazione invece di complementarla.


FitNet Deep: perché vince

- Hint solo su 1ayer4: layer bassi liberi, supervisione sulle semantiche finali
- Come la **vanilla KD**, colma meglio il gap di capacità e lascia a ResNet-18 la libertà di trovare le proprie rappresentazioni.

EFFETTO TEMPERATURA


Salto maggiore FitNet Deep $T=3 \rightarrow 8$ (+0,40 pp), picco a $T=20$. AT non viene influenzata da T. Oltre $T=8$ i guadagni restano modesti: l'aumento della temperatura soffre di diminishing returns.

Allineare l'attenzione al teacher non implica un student migliore




82,16%
Teacher

Attenzione focalizzata sul soggetto: rappresentazione semantica ad alto livello del ResNet-50.



~79,5%
AT + KD

Pattern spaziale quasi identico al teacher: lo student viene sovraregolarizzato.



~80,9%
Vanilla KD

Attenzione non allineata, accuracy superiore: solo i logit vengono trasferiti, con libertà nelle rappresentazioni intermedie.

81,11%
FitNet Deep

Hint solo su layer4; attenzione più diffusa. Supervisione mirata senza copiare la geometria spaziale su tutti i layer.

Conferme e conclusioni



1 · Confermata

- Vanilla KD supera il baseline CE-only (76,75%) fino a **80,92%** a $T=20$
- Guadagno abbastanza costante: **+3,9 / +4,0 / +4,2 pp** a $T=4 / 8 / 20$



2 · Parzialmente confermata

- Solo **FitNet Deep** ($T=20$, 81,11%) batte chiaramente vanilla KD (+0,19 pp)
- Middle si mantiene competitivo (~80,95%); Full e AT non giustificano la complessità aggiuntiva.



3 · Confermata, con sfumature

- La profondità degli hint conta più dell'allineamento forzato su tutti i layer.
- T modesto e non monotono: max +0,40 pp (Deep $T=3 \rightarrow 8$);

RISPOSTA AL QUESITO DI RICERCA

La ResNet-18 distillata supera il baseline su tutti i metodi KD. La strategia migliore è FitNet Deep ($T=20$); più vincoli a livello di feature non implicano accuracy migliore.

FitNet Deep comprime il teacher con ~1 pp di accuratezza persa

TAKEAWAY CHIAVE

Tutti i metodi KD superano il baseline (76,75%) di +2,7–4,4 pp. Il migliore si dimostra FitNet Deep (T=20), seguito da vanilla KD. Lo Student risultante dal processo è 2,1× più piccolo e ~5,5× più veloce del teacher.

⚠ Limiti

- CIFAR-100 a **32×32 nativi**: una risoluzione più alta avrebbe permesso accuracy migliori su teacher e student
- Nessun validation split (500 img/classe); best checkpoint selezionato sul **test set**

→ Lavoro futuro

- **Upscaling** delle immagini (224×224) per spingere il teacher e testare quanto la distillazione trasferisce accuracy più alte
- **Ablation hint layer** guidata dal risultato sulla profondità

Grazie per l'attenzione

Slide di backup

Tabelle dettagliate, ablation e iperparametri

Tutti i risultati con sweep completo della temperatura

Modello	Metodo	T	Top-1 (%)	MB	ms/img
ResNet-50	Teacher (fine-tuned)	—	82,16	90,63	0,172
ResNet-18	Baseline (solo CE)	—	76,75	42,84	0,038
ResNet-18	Vanilla KD	4	80,67	42,84	0,031
ResNet-18	Vanilla KD	8	80,74	42,84	0,029
ResNet-18	Vanilla KD	20	80,92	42,84	0,038
ResNet-18	FitNet Middle S2	3	80,71	42,84	0,026
ResNet-18	FitNet Middle S2	8	80,78	42,84	0,056
ResNet-18	FitNet Middle S2	20	80,95	42,84	0,030
ResNet-18	FitNet Deep S2	3	80,55	42,84	0,049
ResNet-18	FitNet Deep S2	8	80,95	42,84	0,058
ResNet-18	FitNet Deep S2	20	81,11	42,84	0,031
ResNet-18	FitNet Full S2	3	80,51	42,84	0,031
ResNet-18	FitNet Full S2	8	80,76	42,84	0,045
ResNet-18	FitNet Full S2	20	80,62	42,84	0,061
ResNet-18	AT + KD	4	79,52	42,84	0,030
ResNet-18	AT + KD	8	79,45	42,84	0,051
ResNet-18	AT + KD	20	79,62	42,84	0,039

Metriche dal checkpoint Final(best). FitNet Stage 2: T ∈ {3,8,20}. Vanilla KD e AT: T ∈ {4,8,20}.

Vanilla KD: accuratezza cresce monotonicamente con T



+0,25 pp totali da T=4 a T=20. Guadagno rispetto alla baseline: +3,9 / +4,0 / +4,2 pp.

Middle e Deep piccano a T=20; Full è migliore a T=8



FitNet Deep T=3→8: +0,40 pp (salto maggiore). FitNet Full degrada a T=20 (80,62%).

Hint layer FitNet e iperparametri di training

Config	Hint layer	Ragionamento
Middle	layer2 512 ch @ 16×16 → 128 ch	Proposta originale FitNets: guida semantica intermedia
Deep	layer4 2048 ch @ 4×4 → 512 ch	Allinea le rappresentazioni finali del backbone prima del classificatore
Full	layer1–layer4 tutti e 4 gli stage	Supervisione multi-scala continua lungo tutto il backbone

FitNet Stage 1

- 100 ep., lr 5×10^{-4} , SGD
- MSE hint + regressore conv 1×1 con BatchNorm

FitNet S2 / Vanilla KD

- 200 ep., $\alpha=0,1$, scheduler cosine
- SGD lr 0,1, weight decay 5×10^{-4}

Attention Transfer

- $\alpha=0,9$, $\beta=100$, 200 epoche
- Mappe F^2 -sum su layer1–4, cosine annealing

Teacher

- 100 ep., cosine decay
- lr 0,01 (conv1, fc) / 0,001 (backbone pretrained)

Metriche latenza

- Media su 50 batch GPU, 5 batch di warmup
- Confronto ms/immagine teacher vs student

Riproducibilità

- seed=42, stesso checkpoint teacher per ogni run
- Config YAML condivise tra tutti gli script

Latenza inferenza e lavoro originale del progetto



Latenza inferenza (ms/immagine). Tutti gli student $\sim 5,5\times$ più veloci del teacher.

Originale

Pipeline end-to-end PyTorch, ResNet adattate a CIFAR, loss KD/FitNet/AT custom, sweep di T e valutazione efficienza.

Riutilizzato

Backbone ResNet torchvision, pesi ImageNet-1K, dataset CIFAR-100 via torchvision.


Framework modulare

Script teacher, baseline, vanilla KD, FitNets (2 stage), AT — tutti guidati da config YAML.


Riproducibilità

seed=42, stesso checkpoint teacher congelato per ogni run student.

Teacher e baseline: il gap da colmare con la distillazione




Teacher ResNet-50
82,16% top-1 · 100 epoche




Student baseline (solo CE)
76,75% top-1 · 200 epoche

Gap teacher–student: 5,41 pp. Obiettivo della distillazione: avvicinarsi al teacher mantenendo un modello $2,1\times$ più piccolo.


Vanilla KD: l'accuratezza cresce con T fino a 80,92%



T = 4
80,67% top-1




T = 8
80,74% top-1




T = 20
80,92% top-1 · migliore

Trend monotono da T=4 a T=20 (+0,25 pp). Logit ammorbiditi a T più alta guidano meglio lo student verso le relazioni inter-classe del teacher.


FitNet a T=20: Deep guida meglio di Full e Middle



Middle · layer2
80,95% top-1




Deep · layer4 ★
81,11% top-1 · migliore assoluto




Full · layer1-4
80,62% top-1 · degrada vs T=8

La supervisione densa (Full) over-regularizza lo student; Deep allinea solo lo stage semantico finale, lasciando libertà ai layer iniziali.


FitNet Deep: il salto maggiore avviene da T=3 a T=8



T = 3
80,55% top-1




T = 8
80,95% top-1 · +0,40 pp




T = 20
81,11% top-1 · migliore

Da T=8 a T=20 il guadagno è modesto (+0,16 pp). T=3 (valore del paper originale) sottoperforma rispetto a T più alti.


Attention Transfer: training piatto e sotto la vanilla KD



T = 4
79,52% top-1 · migliore AT



T = 8
79,45% top-1



T = 20
79,62% top-1

Accuratezza quasi invariante rispetto a T (79,45–79,62%). L'allineamento spaziale delle attenzioni compete con l'obiettivo di classificazione senza superare la semplice KD sui logit.